KI- & ML-Pipeline — Extruder Live-Monitoring

PM-Project · Datenfluss, Modelle, Layer 1 & Layer 2, Training, Roadmap

Dieses Dokument beschreibt, wie **künstliche Intelligenz (KI)** und **maschinelles Lernen (ML)** im PM-Project Live-Extruder-Monitoring eingesetzt werden: Datenfluss, Modelle, Training und das Zusammenspiel von Layer 1 (Regeln/Baseline) mit Layer 2 (gelerntes Verhalten).

1. Architektur auf einen Blick

Das System hat zwei Auswertungsebenen:

Layer	Name	Ansatz	Fenster	Status
Layer 1	Regeln + Baseline	Z-Score vs. `baseline_registry`, fest codierte Zustandsregeln	~3 Min. (rollierend)	Live in `main.py` (Baseline muss befüllt sein)
Layer 2	ML-gelernt	Clustering → Labels → Klassifikator + Isolation Forest	30 Min.	Offline-Training; `AnomalyScorer` bereit für Live-Anbindung

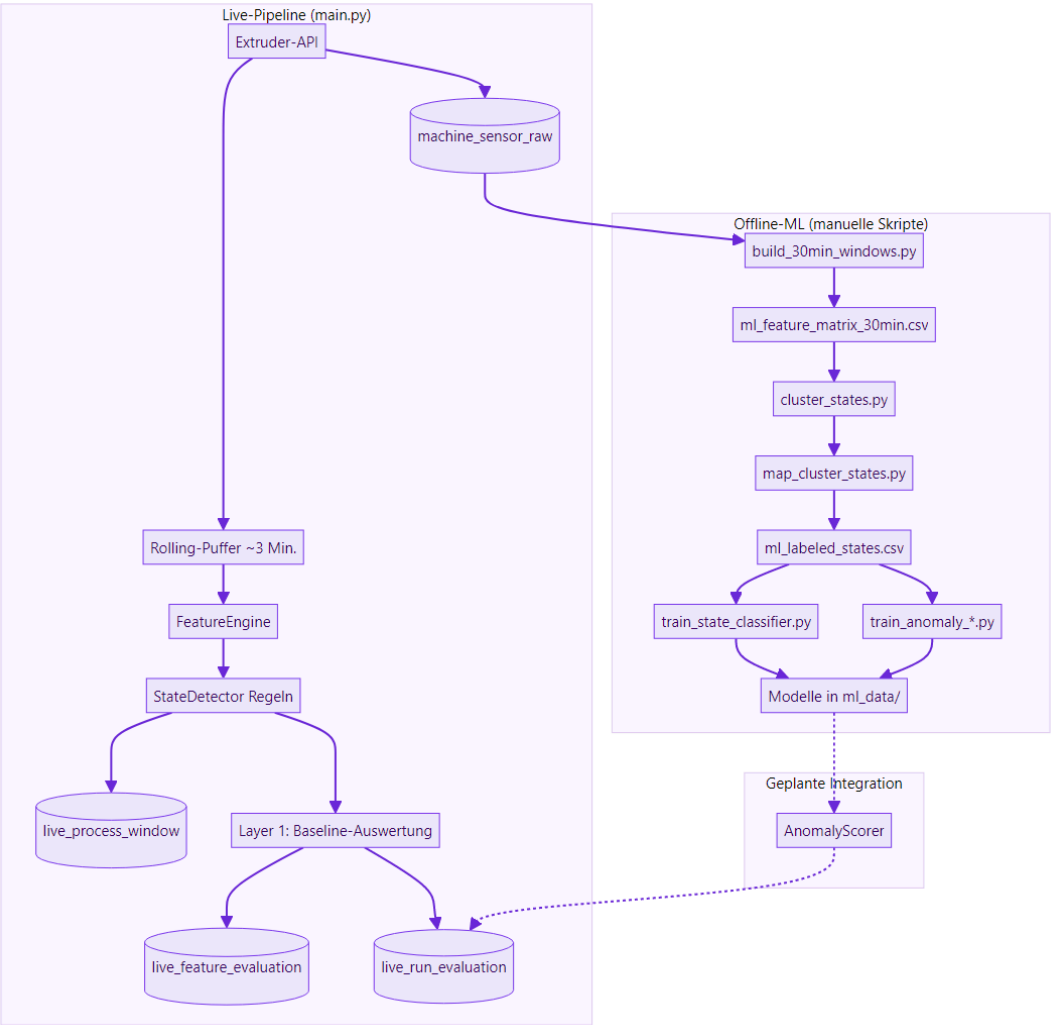

2. End-to-end-Datenfluss

2.1 Live-Erfassung (alle ~10 s)

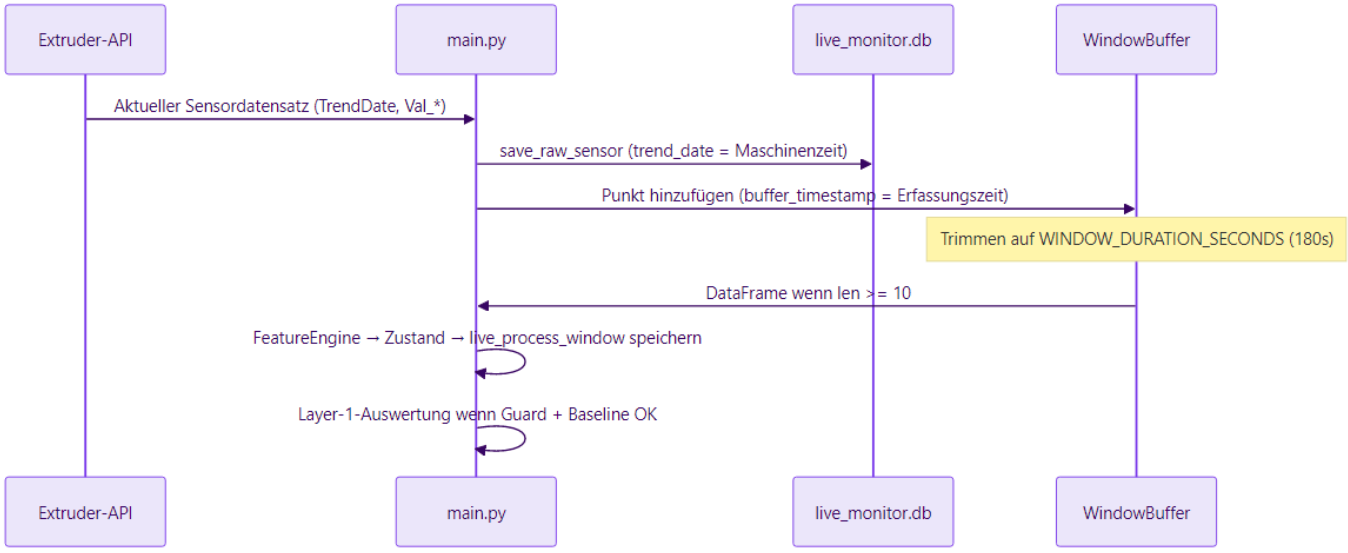

Zeitstempel-Konzept

- `timestamp` / `trend_date` : Maschinenzeit aus der API (`TrendDate`) — für ML-30-Min.-Buckets und Rohspeicherung.
- `buffer_timestamp` : lokale Erfassungszeit — für stabiles 3-Min.-Rolling-Window, wenn API-Zeit verzögert oder unsortiert ist.

2.2 Offline-ML-Aktualisierung (derzeit manuell)

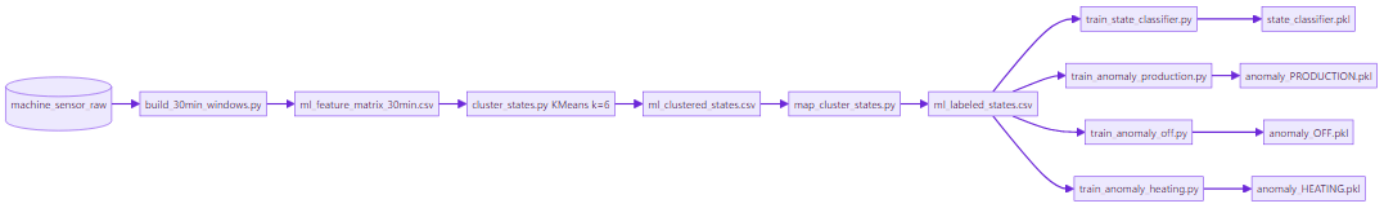

Aus dem Projektroot ausführen:

```
python live_monitor/storage/build_30min_windows.py
python live_monitor/ml/cluster_states.py
python live_monitor/ml/map_cluster_states.py
python live_monitor/ml/train_state_classifier.py
python live_monitor/ml/train_anomaly_production.py
python live_monitor/ml/train_anomaly_off.py
python live_monitor/ml/train_anomaly_heating.py
```

3. Layer 1 — Regel- & Baseline-Auswertung

3.1 Zweck

Aktuelle **3-Minuten**-Fenster-Features mit historischen Statistiken in `baseline_registry` vergleichen (pro Regime: LOW / MID / HIGH).

3.2 Ablauf

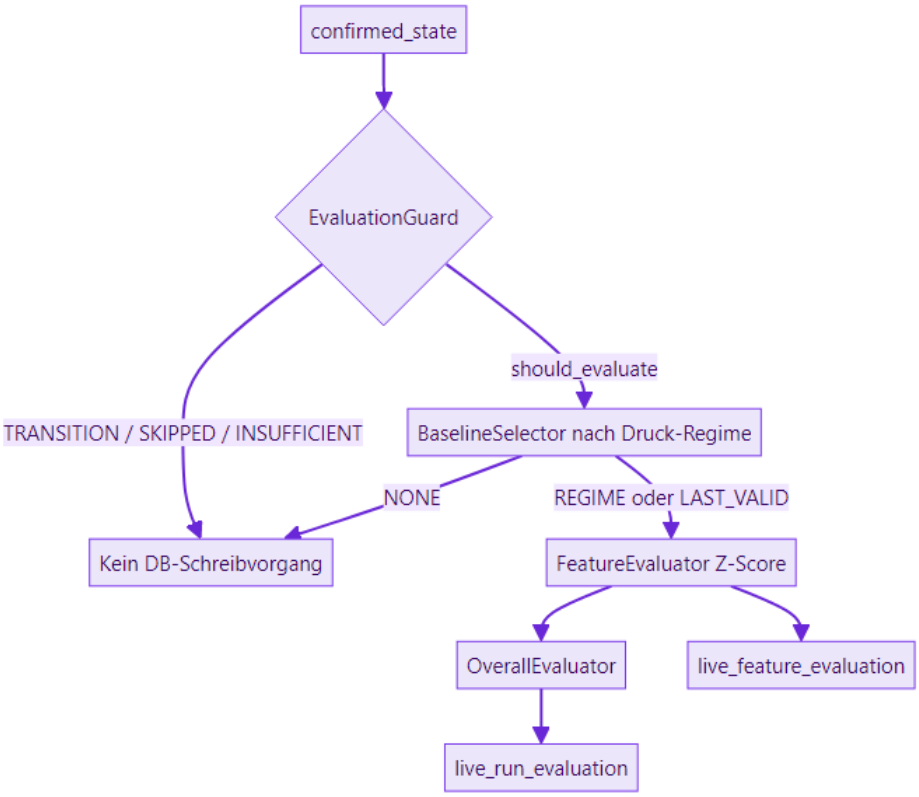

3.3 `overall_status` in `live_run_evaluation`

Zusammengefasst aus dem Status je Feature:

Wert	Bedeutung
`NORMAL`	Alle ausgewerteten Features innerhalb des normalen Z-Bands
`WARNING`	Mindestens ein Feature WARNING (Kern-Features haben Priorität)
`CRITICAL`	Mindestens ein Kern-Feature oder beliebiges Feature CRITICAL

Kern-Features: `pressure_mean`, `screw_speed_mean`, `temperature_mean`, `pressure_per_rpm`.

Z-Score-Bänder (in `feature_evaluator.py`): `|z| < 1.5` → NORMAL; `1.5–2.5` → WARNING; `≥ 2.5` → CRITICAL.

Voraussetzung: `baseline_registry` muss befüllt sein (`storage/populate_baseline.py`).

4. Layer 2 — ML-gelernte Auswertung

4.1 Pipeline-Stufen

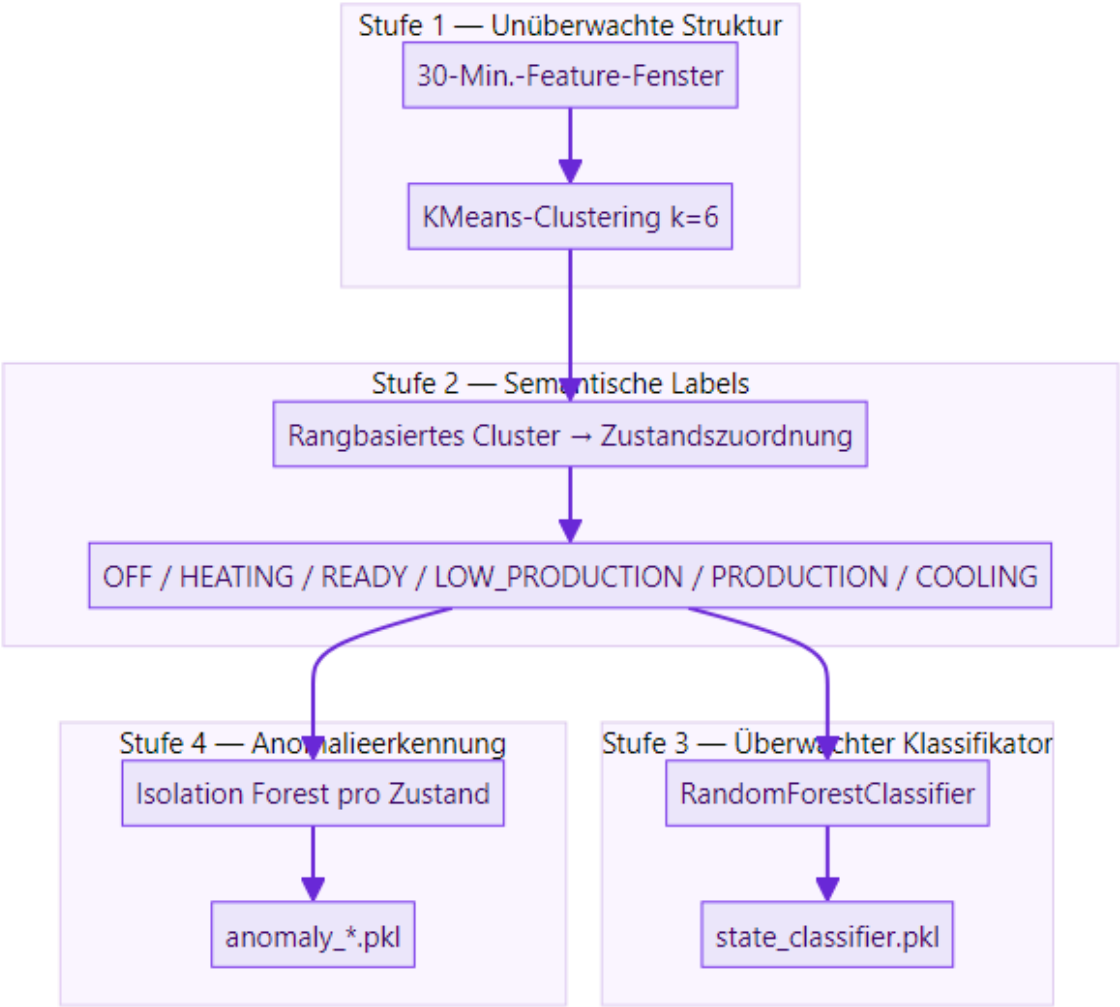

4.2 30-Minuten-Fenster-Features

Erzeugt in `storage/build_30min_windows.py` aus `machine_sensor_raw`, gruppiert nach `TrendDate`:

Feature-Gruppe	Beispiele
Niveau-Statistiken	`mean_Val_1`, `std_Val_6`, `min_*`, `max_*`, `range_*`
Abgeleitete Kennzahlen	`pressure_per_rpm`, `load_per_pressure`
Trends (Steigungen)	`slope_Val_1`, `slope_Val_6`, `slope_temperature`
Qualität	`row_count`, `valid_fraction`, `regime`, `is_stable`

Steigungsberechnung: Pro 30-Min.-Bucket wird eine Gerade `Wert ~ Zeit_sekunden` mit `numpy.polyfit(..., 1)` angepasst; der Koeffizient ist die Steigung (Änderung pro Sekunde). Weniger als 2 Punkte → Steigung `0`.

4.3 Clustering → Zustandslabels

- **Eingabe:** `ml_feature_matrix_30min.csv`
- **Algorithmus:** KMeans mit `k=6` (Elbow-Plot als `elbow_plot.png`)
- **Zuordnung:** `map_cluster_states.py` weist Cluster-IDs per Rangregeln (Drehzahl, Druck, Temperatursteigung usw.) Betriebszuständen zu.
- **Ausgabe:** `ml_labeled_states.csv` mit `cluster_id` und `predicted_state`

4.4 Zustandsklassifikator

Punkt	Detail
Skript	`ml/train_state_classifier.py`
Modell	Random Forest (`class_weight=balanced`)
Split	**80/20 chronologisch** nach `window_start` (vermeidet Leakage durch überlappende Fenster)
Artefakte	`state_classifier.pkl` , `state_classifier_scaler.pkl`

4.5 Anomalieerkennung (Isolation Forest)

Ein Modell pro Maschinenzustand, sofern genügend gelabelte Daten vorhanden sind:

Zustand	Trainingsskript	Artefakte	Registry-Status
PRODUCTION	`train_anomaly_production.py`	`anomaly_PRODUCTION.pkl` + Scaler	ready
OFF	`train_anomaly_off.py`	`anomaly_OFF.pkl` + Scaler	ready
HEATING	`train_anomaly_heating.py`	`anomaly_HEATING.pkl` + Scaler (Feature-Teilmenge)	ready
LOW_PRODUCTION, COOLING, READY	—	—	insufficient_data

Training nutzt **stabile** Fenster des jeweiligen Zustands (z. B. PRODUCTION + `is_stable=True`). Bei Inferenz liefert `AnomalyScorer` (`ml/anomaly_scorer.py`):

- Lädt Modelle über `ml/model_registry.py`
- Bewertet Live-Feature-Dict für `confirmed_state`
- Gibt zurück: `ml_anomaly_score` , `ml_is_anomaly` , `ml_model_status`

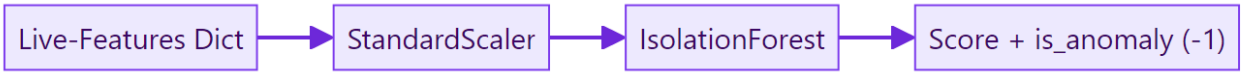

5. Datenbanktabellen (KI/ML-relevant)

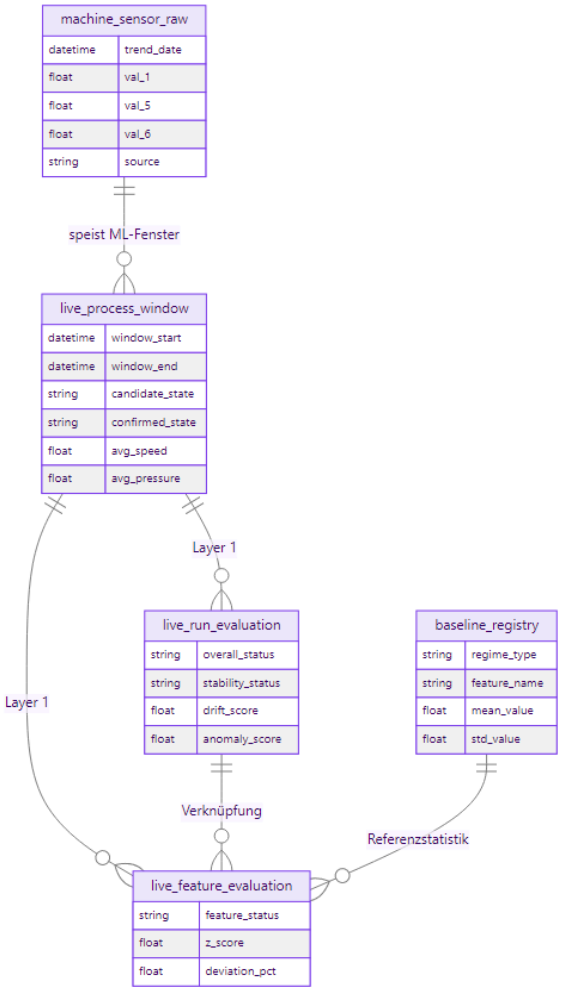

6. Projektstruktur (ML-Module)

```
live_monitor/
  main.py                       # Live-Schleife + Layer 1
  config.py                     # API, Fenster, ML-Pfade, Schwellenwerte
  ingestion/api_client.py       # Abfrage + Normalisierung Sensoren
  processing/
    window_buffer.py            # 3-Min.-Rolling-Puffer
    feature_engine.py           # Live-Fenster-Features
  state/state_detector.py       # Regelbasierte Zustände (+ ANOMALY-Grenzen)
  evaluation/                   # Layer 1
    evaluation_guard.py
    baseline_selector.py
    feature_evaluator.py
    overall_evaluator.py
  storage/
    build_30min_windows.py      # ML-Feature-Matrix
    populate_baseline.py        # Layer-1-Baselines
    db_writer.py                # SQLAlchemy-Modelle
  ml/
    cluster_states.py           # KMeans
    map_cluster_states.py       # Cluster → Zustandsname
    train_state_classifier.py
    train_anomaly_production.py
    train_anomaly_off.py
    train_anomaly_heating.py
    anomaly_scorer.py           # Live-Inferenz-Helfer
    model_registry.py           # Modellpfade + Bereitschaft
  ml_data/                      # CSVs + .pkl-Artefakte
  api/routes.py                 # REST für Live + Baseline
```

7. Roadmap: Ist vs. Ziel

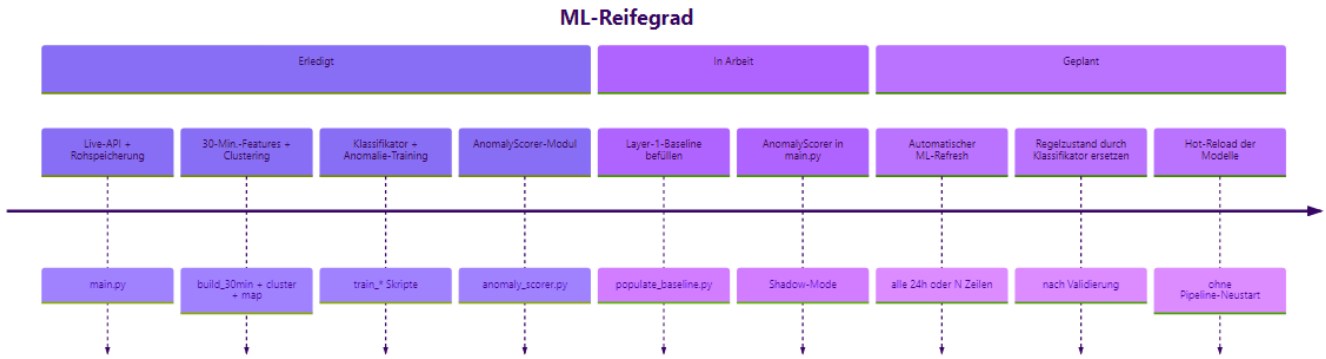

Empfohlene Reihenfolge (vereinbart)

1. Layer-2-Modelle manuell validieren (Metriken, Confusion Matrix, Cluster stichprobenartig prüfen).
2. Layer 2 im **Shadow-Mode** parallel zu Layer 1 betreiben (beides loggen, Alerts noch nicht umstellen).
3. Layer-1-Baseline-Pfad nur als Fallback stabilisieren.
4. Layer 2 zur primären Auswertung machen; automatisches Retraining zuletzt.

8. Wichtige Konfiguration (`config.py`)

Einstellung	Standard	Rolle
`POLL_INTERVAL_SECONDS`	10	Live-Abfrageintervall
`WINDOW_DURATION_SECONDS`	180	Layer-1-Rolling-Fenster
`ML_WINDOW_MINUTES`	30	ML-Aggregations-Bucket
`ML_WINDOW_MIN_ROWS`	10	Min. Punkte pro 30-Min.-Fenster
`CONFIRMATION_WINDOWS`	3	Zustandsbestätigung
`ML_OUTPUT_DIR`	`live_monitor/ml_data`	Artefakte + CSVs
`DB_CONNECTION_STRING`	`sqlite:///live_monitor.db`	Datenbank

9. Artefakte in `ml_data/`

Datei	Beschreibung
`ml_feature_matrix_30min.csv`	30-Min.-Fenster für ML
`ml_clustered_states.csv`	+ `cluster_id`
`ml_labeled_states.csv`	+ `predicted_state` (Trainingslabels)
`state_classifier.pkl` / `state_classifier_scaler.pkl`	Zustandsklassifikator
`anomaly_PRODUCTION.pkl` / `*_scaler.pkl`	Anomalie-Modell Produktion
`anomaly_OFF.pkl` / `anomaly_HEATING.pkl`	zustandsspezifische Anomalie
`elbow_plot.png`	KMeans-Elbow-Diagnose

Optional (Legacy): `ml_feature_matrix.csv` (4-Min.-kombinierter Datensatz) — wird vom 30-Min.-Clustering-Pfad nicht verwendet.

10. Glossar

Begriff	Bedeutung
TrendDate	Maschinenzeitstempel aus der API; steuert ML-30-Min.-Gruppierung
Regime	Druckband: LOW (<280), MID (280–320), HIGH (>320 bar)
Stabiles Fenster	Geringe Variabilität bei Drehzahl/Druck-Kennzahlen (`is_stable` -Flag)
Z-Score	Layer-1-Abweichung vom Baseline-Mittelwert in Standardabweichungen
Isolation Forest	Unüberwachte Anomalieerkennung; `-1` = Anomalie
Shadow-Mode	ML-Vorhersagen ausführen, ohne Produktions-Alerts zu ändern

11. Verwandte Dokumentation

- Betriebs-Runbook: `live_monitor/README.md`
- Historische Segmentierung (Stage 2): `timeSeriesDB/.../process_segmentation_outputs/README.md`

Zuletzt aktualisiert: Projektstand mit Layer 1 in `main.py`, Layer-2-Trainingsartefakten in `ml_data/` und `AnomalyScorer` zur Live-Integration vorbereitet.